탱크 강화학습 진행보고서(2026_04_14)

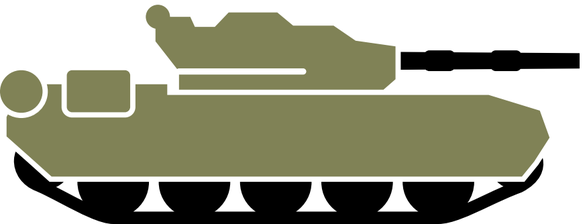

강동욱

등장인물

Learner

- 현재 학습중인 NN
- PPO로 계속 업데이트 됨

VS

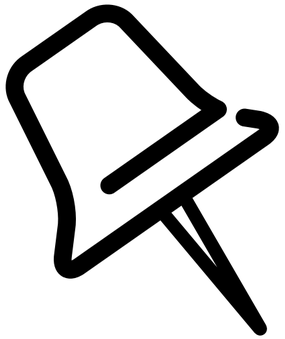

Pool

- NN 가중치의 스냅샷(fixed)리스트
- 시험을 통과하면 해당 모델의 파라미터는 풀에 들어갈 수 있음
- 평소 Learner는 Pool에서 랜덤으로 추출한 모델과 전투를 진행

POOL?

Pool (init,50iter,100iter,250iter, ...)

1. 초기 pool은 init NN(랜덤 가중치) -> ("init")
2. 50iter마다 Learner는 학습을 멈추고 시험을 치룸
3. pool 안에 존재하는 각 모델과 256번씩 전투를 진행
4. 평균 승률이 60%가 넘는다면 해당 Learner 모델(50n iter)은 pool에 등록
   -> ("init", 100iter)
5. pool의 최대 길이는 10, 그 이상은 가장 오래된 모델을 버리는 구조(FIFO)
6. Learner는 50% 확률로 자기자신과, 50% 확률로 Pool에서 랜덤 추출한 모델과 전투 후 학습

풀이 커질수록 "다양한 전략을 이기는 NN"이 됨 → 특정 상대에만 최적화 되는 overfitting 방지.

용어정리

obs(65차원):NN이 매 step받는 입력

- 아군 3대 × 7 (x, y, yaw, hp, 재장전 쿨다운, left_speed, right_speed)
- 적 3대 × 6 (x, y, yaw, hp, 재장전 쿨다운, alive)
- 엄폐물 6개 × 4 (x, y, 폭, 높이)
- 시간 진행률 (0→1)
- 자기장 반변 (현재 안전 영역 크기, 20m -> 8m)

done: 에피소드 종료 여부

- 시뮬레이션 기준 120초 Time out 혹은 한쪽팀 전멸시 True

추가 기재사항

- 시뮬 1초 = 400 physics steps (1 / 0.0025) -> 이건 고정된 값
- 전투 1회(120초) = 48,000 physics steps
- 시뮬 1초 ≈ 현실 5초 -> 현재 컴퓨터 기준(GPU 성능, env 수, CPU 등에 따라 달라짐)
- 전투 1회(120초 sim) ≈ 현실 ~10분
- 각 NN은 20step마다 새로운 obs를 받고 action을 출력

Reward

이벤트	보상
적 명중	+0.4
아군 피격	-0.4
적 격파 (HP→0)	+1.5
아군 사망	-1.0
승리 (적 전멸)	+5.0
패배 (아군 전멸)	-5.0
무승부/타임아웃	-1.0
매 스텝 시간 패널티	-0.001
종료 시 HP 보너스	+0.3 × Σ(잔여 HP)

학습 과정

Learner vs Pool(random) 혹은 self(자기자신)

NN은 64step이 되면 옆 참고자료와 같이 쌓인 data에 대해서 미니배치로 나누고 에폭만큼 반복 학습 진행

- 배치 크기 = 2048 × 64 / 4 = 32,768 samples/batch
- 에폭: 5 epochs/iteration

2048 envs × 64 steps = 131,072 샘플 → 4등분(32,768씩) × 5에폭 = 총 20번 gradient update가 1 iteration

50 iteration이 쌓이면 Pool 검증 진행

현재 400 iteration 정도 (진행중)

참고자료

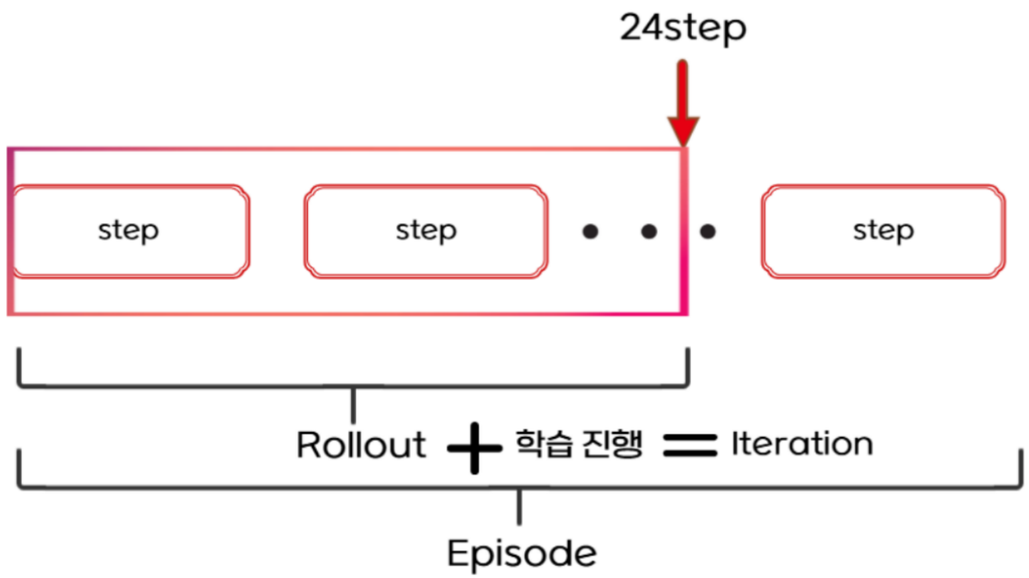

NN 구조

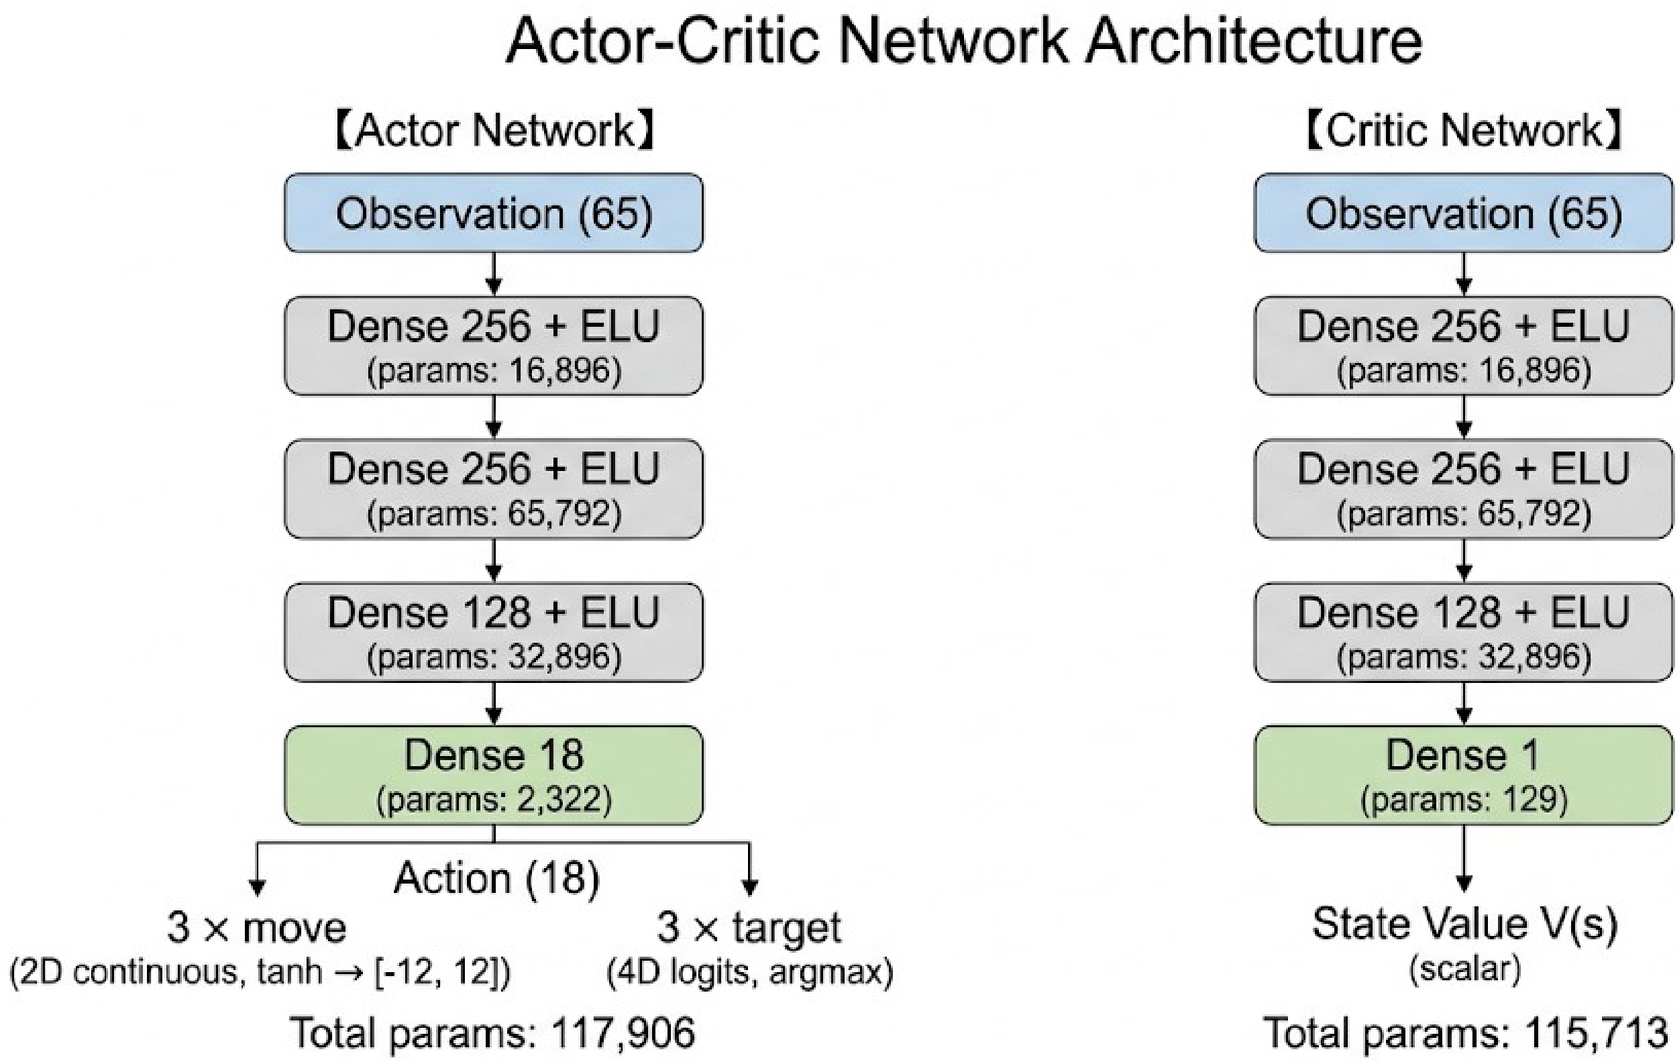
Actor-Critic Network Architecture
【Actor Network】
Observation (65)
Dense 256 + ELU
(params: 16,896)
Dense 256 + ELU
(params: 65,792)
Dense 128 + ELU
(params: 32,896)
Dense 18
(params: 2,322)
Action (18)
3 × move
(2D continuous, tanh → [-12, 12])
3 × target
(4D logits, argmax)
Total params: 117,906
【Critic Network】
Observation (65)
Dense 256 + ELU
(params: 16,896)
Dense 256 + ELU
(params: 65,792)
Dense 128 + ELU
(params: 32,896)
Dense 1
(params: 129)
State Value V(s)
(scalar)
Total params: 115,713